


Trabajo Práctico 1 – Gradiente de Política

Joaquín Di Cola


1. Entornos de prueba y desempeño

Los cuatro entornos personalizados permiten aislar distintos componentes de REINFORCE antes de utilizarlo en problemas de mayor complejidad.


Entorno	Componente que permite debuggear
TwoAZeroObsOneStep	Verifica el funcionamiento básico del gradiente de política: muestreo de una política estocástica, cálculo de $\log \pi_{\theta}(a s)$ y refuerzo de la acción que produce mayor recompensa.
TwoARandomObsOneStep	Verifica que la política utilice correctamente la observación y aprenda acciones distintas según el estado, en lugar de converger simplemente a una acción global.
LineWorldEasyEnv	Verifica el cálculo del reward-to-go y del factor de descuento γ . Como la única recompensa positiva aparece al alcanzar el objetivo, permite detectar errores en la asignación de crédito a acciones tomadas varios pasos antes.
LineWorldMirrorEnv	Verifica que la política dependa efectivamente del estado y que las transiciones se procesen correctamente. Una política trivial de “siempre derecha” falla porque en el segundo estado las acciones están invertidas.




(a) TwoAZeroObsOneStep




(b) TwoARandomObsOneStep




(c) LineWorldEasyEnv



(d) LineWorldMirrorEnv



(e) CartPole-v1



(f) Acrobot-v1

Figura 1: Recompensa o longitud de episodio durante el entrenamiento. Se muestran también las referencias correspondientes a agentes aleatorios y triviales cuando alcanzan el estado terminal.

2. Pérdida de la política

Las siguientes curvas muestran la contribución a la pérdida de política por episodio. Como es habitual en aprendizaje reforzado, la loss no presenta necesariamente una evolución monótona aun cuando el desempeño del agente mejore.




Figura 2: Pérdida de la red de política por episodio para los seis entornos.

Entorno de mayor dificultad

El entorno que presentó la convergencia más lenta fue **Acrobot-v1**. A diferencia de los entornos simples, el agente debe generar una secuencia de acciones que acumule suficiente energía para elevar el extremo del sistema. El espacio de observación es continuo y de seis dimensiones, existen tres acciones posibles y las consecuencias relevantes de una acción pueden manifestarse varios pasos después. Esto dificulta la asignación de crédito y aumenta la varianza del estimador de gradiente. En la versión sin baseline, el agente permaneció durante gran parte del entrenamiento cerca del retorno mínimo antes de comenzar a mejorar.

Parte más demandante

La parte más demandante en tiempo fue ajustar, ejecutar y comparar los entrenamientos de CartPole y Acrobot; una mejora posible habría sido fijar seeds y automatizar desde el comienzo el guardado de métricas, pesos y figuras para facilitar comparaciones reproducibles.

3. REINFORCE con baseline

Se extendió REINFORCE incorporando una red de valor $V_\phi(s)$ y utilizando la ventaja estimada

$$A(t) = R(t) - V_\phi(s_t)$$

como señal para actualizar la política. La red de valor fue ajustada por regresión utilizando el retorno real como objetivo.




Figura 3: Comparación entre REINFORCE y REINFORCE con baseline.

En **CartPole-v1**, ambas variantes resolvieron exitosamente el entorno. La versión sin baseline alcanzó el umbral de una media móvil de 475 en el episodio 1873, mientras que en la corrida reportada, la versión con baseline lo hizo en el episodio 2175. Las diferencias entre corridas fueron sensibles a la estocasticidad del entrenamiento, por lo que en este entorno no se observó una mejora consistente en velocidad de convergencia.

En **Acrobot-v1**, el efecto del baseline fue mucho más marcado. La versión con baseline superó de forma sostenida el umbral de -100 alrededor del episodio 3071, mientras que la versión sin baseline no llegó a superarlo de forma sostenida en su media móvil durante los 5000 episodios. La política determinista final con baseline obtuvo un retorno medio de aproximadamente $-88,23$, confirmando que el entorno fue resuelto.

Entorno	REINFORCE	REINFORCE + baseline
CartPole-v1 – retorno determinista	500.00	500.00
Acrobot-v1 – retorno determinista	-81.36	-88.23

Videos de evaluación determinista:

CartPole-v1: video

Acrobot-v1: video